




ANÁLISE BAYESIANA DE CLASSES LATENTES APLICADA À CRIMINALIDADE NO ESTADO DO RIO DE JANEIRO

Matheus Jun Onishi da Silva, Jony Arrais Pinto Junior
Universidade Federal Fluminense
majun@id.uff.br, jarrais@id.uff.br



Introdução

- A criminalidade no estado do Rio de Janeiro apresenta uma **diversidade de delitos** distribuídos de forma **desigual entre as regiões**, refletindo a **dinâmicas sociais, econômicas e territoriais complexas** [1].
- A heterogeneidade observada exige **abordagens multivariadas** para compreender os **padrões criminais**.
- A **Análise de Classes Latentes** (LCA, do inglês *Latent Class Analysis*) é uma técnica eficaz para modelar **padrões latentes** em dados sociais [2].
- Neste estudo, utilizou-se a **LCA sob a perspectiva bayesiana** para analisar os dados de criminalidade do estado do Rio de Janeiro, com o intuito de identificar **perfis ocultos da incidência criminal** no estado.

Objetivos

- Aplicar a **Análise de Classes Latentes (LCA)**, sob a **perspectiva bayesiana**, para identificar **perfis ocultos** de criminalidade no estado do Rio de Janeiro.

Materiais

- Área de Estudo:** As 137 **Circunscrições Integradas de Segurança Pública (CISPs)** do estado do Rio de Janeiro, no período de 2020 a 2023.
- Fonte:** Instituto de Segurança Pública do Rio de Janeiro (ISP-RJ).
- Dados:** Registros de múltiplos tipos de delitos, incluindo:
 - Crimes violentos, Crimes de trânsito, Roubos, Furtos, Crimes contra o patrimônio, Atividades policiais e Outros delitos.
- Pré-processamento:**
 - Cálculo dos totais acumulados por CISP.
 - Dicotomização:** classificação em *alta* ou *baixa incidência* conforme o primeiro quartil de cada tipo de crime.

Metodologia

Análise de Classes Latentes (LCA)

- Aplicação da **LCA sob a ótica bayesiana**, como abordado por Li et al. [3].
- O modelo assume:
 - Existência de uma variável latente C que representa a **heterogeneidade não observada** entre subgrupos.
 - Independência condicional** entre as variáveis observadas, dado $C = j$.
- Entrada: **Variáveis dicotômicas**, facilitando **aplicação computacional** [2].
- Função de verossimilhança para G classes latentes:

$$P(\pi, \theta | Y_i = y_i) = \sum_{j=1}^G \pi_j \prod_{k=1}^K \theta_{jk}^{y_{ik}} (1 - \theta_{jk})^{1-y_{ik}}$$

- Parâmetros:
 - π_j : probabilidade da CISP pertencer à classe j .
 - θ_{jk} : probabilidade condicional de **alta incidência** no crime k , dada a classe j .
- Objetivo: Estimar o vetor de **probabilidades de classe** π e as **probabilidades condicionais** θ_j .

Implementação Computacional

- Linguagem:** R, utilizando RStudio.
- Modelagem:** pacote BayesLCA [4].
- Estimativas:** função `blca.gibbs`, com amostrador de Gibbs.
- Manipulação de dados:** pacotes do `tidyverse`.
- Visualização:** mapas temáticos interativos com o pacote `leaflet`.

Resultados

A aplicação do modelo de **Análise de Classes Latentes (LCA) bayesiana**, por meio da função `blca.gibbs`, identificou **duas classes latentes** ($G = 2$), cujos resultados estão apresentados na Tabela 1.

Os resultados evidenciam a existência de **duas classes bem definidas**:

- Classe 1** — perfis com **alta incidência criminal geral**.
- Classe 2** — perfis com **baixa incidência criminal geral**.

Tabela 1: Probabilidades das Classes Latentes e Condicionais com Intervalos de Credibilidade (95%)

Parâmetros	Classe 1	Classe 2	IC Classe 1	IC Classe 2
Probabilidade da Classe (π_j)	0,73	0,27	[0,65; 0,80]	[0,19; 0,34]
Crimes Violentos (θ_{j1})	0,97	0,13	[0,93; 0,99]	[0,02; 0,23]
Crimes de Trânsito (θ_{j2})	0,97	0,14	[0,93; 0,99]	[0,03; 0,24]
Roubos (θ_{j3})	0,94	0,21	[0,89; 0,98]	[0,08; 0,33]
Furtos (θ_{j4})	0,97	0,13	[0,93; 0,99]	[0,03; 0,24]
Crimes contra o Patrimônio (θ_{j5})	0,98	0,11	[0,95; 0,99]	[0,02; 0,20]
Atividade Policial (θ_{j6})	0,91	0,28	[0,85; 0,96]	[0,14; 0,42]
Outros Registros (θ_{j7})	0,97	0,13	[0,93; 0,99]	[0,03; 0,23]

Com as estimativas, foram calculadas as **probabilidades a posteriori de pertencimento** de cada CISP às classes latentes, denotadas por $C_i | (Y_i, \pi, \theta)$, possibilitando a **classificação probabilística** das CISPs, conforme mostra a Figura 1.




Figura 1: Distribuição espacial das probabilidades a posteriori de pertencimento à Classe 1. Fonte: Elaborado pelo autor (2024).

A Figura 1 revela uma **divisão espacial clara** entre as regiões de alta e baixa probabilidade de pertencimento à **Classe 1**, **sem zonas de transição nítidas**. As áreas em **vermelho** indicam maior probabilidade de pertencer à **classe de alta criminalidade**, enquanto os tons **amarelos** representam menor probabilidade.

Destacam-se como **regiões de baixa criminalidade** o **norte fluminense** e a **região serrana**. Enquanto a **Região Metropolitana**, especialmente a **capital** e a **Baixada Fluminense**, concentram as **maiores probabilidades de pertencimento à classe de alta criminalidade**.

Considerações finais

- A aplicação da **Análise de Classes Latentes (LCA)** permitiu identificar **agrupamentos de CISPs com perfis criminais semelhantes**, distinguindo **dois grupos**: alta e baixa incidência de delitos.
- A **segmentação obtida** evidenciou padrões claros, **mesmo sem considerar explicitamente a dependência espacial** entre as unidades territoriais.
- As **probabilidades a posteriori** proporcionaram uma **visão preliminar da distribuição espacial** desses perfis criminais no estado do Rio de Janeiro.
- Os resultados reforçam a **LCA como ferramenta exploratória robusta** para análise de dados criminais e destacam a **necessidade de modelos que incorporem estruturas espaciais**, como as **Classes Latentes Espaciais**, visando análises mais precisas e apoio à **formulação de políticas públicas**.

Agradecimentos e Anexos

Este trabalho deriva de um projeto de Iniciação Científica apoiado pela FAPERJ, a quem agradecemos. As análises utilizam o código disponível abaixo.



Referências

- [1] L. O. Carvalho, B. G. Monteiro, and L. Andrade. Análise multivariada da criminalidade no estado do rio de janeiro. *Revista Brasileira de Ciências Criminais*, 28(163):113–136, 2020.
- [2] L. M. Collins and S. T. Lanza. *Latent Class and Latent Transition Analysis: With Applications in the Social, Behavioral, and Health Sciences*. Wiley, Hoboken, 2010.
- [3] Y. Li, J. Lord-Bessen, M. Shiyko, and R. Loeb. Bayesian latent class analysis tutorial. *Multivariate Behavioral Research*, 53(3):430–451, 2018.
- [4] A. White and T. B. Murphy. Bayeslca: An r package for bayesian latent class analysis. *Journal of Statistical Software*, 61(13):1–28, 2014.